

PlantMR：面向植物和作物、具有环境效应异质性感知能力的可审计摘要统计孟德尔随机化工具包

[作者姓名、单位和通讯作者信息待补]

中文阅读稿 | PlantMR v1.1.0-paper | 2026 年 9 月 19 日

稿件说明 本文件是英文投稿手稿的完整中文翻译，科学内容、分析、源数据、模拟和软件版本与英文稿一致。作者信息、公开归档 DOI 和最终期刊格式仍需在投稿前补充。

摘要

中文阅读稿 | 英文投稿稿的完整翻译，统计结果和引用保持一致

PlantMR v1.1.0-paper

背景

植物孟德尔随机化（Mendelian randomization, MR）可以把分子性状与农艺表型联系起来，但植物参考基因组组装、环境分层、连锁不平衡（linkage disequilibrium, LD）和样本重叠信息常常没有被明确记录。我们开发了 PlantMR 1.1，这是一个本地运行、开源、可审计的植物和作物摘要统计 MR 工具，同时提供范围明确的环境效应异质性分析。

结果

PlantMR 能够检查植物元数据和摘要统计量、协调等位基因、强制建立完整的 SNP×环境工具变量网格、接收带符号的 SNP-LD 矩阵和环境相关矩阵，并报告考虑矩阵秩的异质性诊断。在每个场景 500 次重复的模拟中，考虑协方差的估计器在零假设下的拒绝率为 0.054，95%覆盖率为 0.946；当真实环境斜率为 0.25 时，平均估计值为 0.2498，偏差为 -0.00018，覆盖率为 0.952，功效为 1.00。在 AR(1) LD 相关系数 $\rho=0.6$ 的 LD 压力测试中，正确建模协方差时拒绝率为 0.044、覆盖率为 0.956，而将观测当作独立时分别为 0.126 和 0.874。真实 Arabidopsis 数据契约案例针对 AT1G11560 和 10°C、16°C 开花时间，最终保留了 48 个存在 LD 相关的工具变量。主要分析的环境斜率为 -0.0371（SE 0.1562， $P=0.812$ ），残余异质性为 $Q=192.89$ ， $df=60$ ， $P=7.33 \times 10^{-16}$ 。

结论

PlantMR 提供了一个面向植物的可复现实现和审计工作流。在本研究测试的场景下，模拟结果支持考虑协方差的校准方式；但 Arabidopsis 案例只是软件演示，并不是独立的因果验证。PlantMR 不能替代共定位、正式的交互 MR 方法、混合模型 GWAS 或功能验证。

关键词：孟德尔随机化；植物基因组学；作物基因组学；基因型—环境互作；表达数量性状位点；连锁不平衡；摘要统计量；可复现性

背景

孟德尔随机化使用与暴露相关的遗传变异作为工具变量，估计遗传代理暴露对结局的影响。[1,2] 工具变量的相关性、可交换性和排除限制假设是解释结果的基础，但这些假设能否成立，取决于研究群体、表型、分子暴露以及数据生成过程。摘要统计 MR 可以借助公开的全基因组关联研究（genome-wide association study, GWAS）和 MR-Base 等平台开展大规模分析，[10] 但摘要关联同样容易受到弱工具变量、水平多效性、LD 和样本重叠的影响。[3–9]

植物研究还带来一些额外问题。自然群体和育种群体可能具有明显的地理结构和亲缘关系。不同物种、群体和基因组区域的 LD 衰减速度可能差别很大。基因表达强烈依赖组织、发育阶段和处理条件。多环境试验和胁迫实验经常多个条件下重复测量相同基因型，因此得到的是相关估计，而不是相互独立的 GWAS 数据集。多倍体剂量、存在/缺失变异和结构变异还需要不同的数据表示，不能在没有说明的情况下全部转换成普通的双等位基因 SNP；近期的 Arabidopsis 泛基因组研究说明，局部适应和非参考序列变异应当保持明确记录。[35]

已有植物软件说明了整合式工作流的价值。MRBGR 提供了面向玉米的大规模多组学、GWAS 和 MR 工具箱。[17] 本研究所参考的玉米干旱研究利用动态 eQTL 和先导 eQTL MR 工作流对候选基因进行了优先排序。[18] 植物基因型—环境互作 GWAS 和多环境荟萃分析方法也表明，环境对比、群体结构和交互项需要联合建模，不能只把环境当作标签处理。[25–27] 在植物研究之外，MR-GxE 利用基因—协变量交互来检测或校正恒定多效性假设下的多效性偏倚，[14] 而基于交互的 MR 研究则区分了 MR-GxE 和 MR-GENIUS，并强

调交互强度及模型假设的敏感性。[15] MR-EILLS 针对异质 GWAS 摘要数据中的不变因果效应，并评估了多种 MR 和荟萃分析比较方法。[16] 这些方法的估计目标不同，不能混为一谈。

本文将 PlantMR 开发为一个面向植物和作物的摘要统计软件及报告工作流。其贡献有意区别于一般交互 MR 理论：第一，建立明确的植物元数据和摘要统计数据契约；第二，选择完整的 SNP×环境工具变量网格；第三，接收带符号的 LD 和环境相关性输入；第四，报告考虑矩阵秩的异质性诊断；第五，通过模拟和真实 Arabidopsis 数据契约案例提供可复现的本地实现。我们评估的是校准、LD 错配风险和适用边界，而不是声称发现了新的因果基因。

实现

研究问题和工作流

我们预先设定了四个问题：（1）软件能否执行面向植物、可审计的数据契约；（2）在 SNP 误差和环境误差相关的情况下，考虑协方差的环境斜率估计器能否恢复已知效应；（3）当 LD 和环境依赖性被错误地当作独立时，推断会恶化到什么程度；（4）同一套审计记录能否在真实植物数据契约上运行，同时避免把演示结果写成因果基因结论？图 1 将这些问题分成输入来源记录、协调、工具变量筛选、协方差设定、估计和报告几个阶段。




图 1。PlantMR 工作流示意图。植物材料背景和重复环境测量进入共同的 SNP×环境网格，再进入考虑协方差的估计，并分别输出统计结果和可追溯的复现材料。

PlantMR 软件契约和分析工作流

PlantMR 接收包含 SNP、效应等位基因、另一等位基因、beta、标准误和 P 值的暴露表和结局表。可选字段包括效应等位基因频率和样本量。植物元数据记录物种、参考基因组组装、性状、组织、发育阶段、环境、多倍体信息和 LD 面板来源。软件会检查数值和等位基因，协调反向及互补等位基因，识别有歧义的回文变异，执行 P 值、MAF 和 F 统计量筛选，并记录每一项排除。

表 1。PlantMR 的组成、范围和审计输出。

组成部分	功能	输出
------	----	----

数据模式和元数据	检查摘要统计量和植物背景信息	检查信息和元数据 JSON
等位基因协调	对齐效应等位基因并处理回文变异	协调后的表格和排除数量
工具变量质量控制	P 值、MAF、F 统计量和完整网格筛选	工具变量审计表和保留 SNP 表
标准 MR	Wald 比值、固定/随机效应 IVW、MR-Egger、Q 和留一法	JSON、TSV 和 Markdown 报告
环境斜率	对 SNP×环境比值估计进行 GLS	汇总效应、斜率、协方差秩和 Q
可复现性	命令行接口、测试、模拟和源数据记录	带版本的报告和基准结果

命令行接口提供 validate、run、run-stratified 和 run-gxe 命令。软件不会在没有明确说明的情况下，用 SMR、GSMR、共定位、MVMR、MR-PRESSO、MR-GxE、MR-GENIUS 或 MR-EILLS 替代当前分析。

与相关工具的比较

按照近期 Plant Methods 软件论文的组织方式，我们在展示基准结果之前，先将 PlantMR 与功能相邻的工具进行比较。这是基于相关软件论文和公开文档的范围与数据契约比较，不是虚构的运行时间头对头实验。PlantMR 的目标是把植物元数据、完整 SNP×环境网格、带符号的 LD/环境协方差和可审计的摘要统计输出组合在一起。

表 2。与相关工具的功能定位比较。“不是主要关注点”表示某个工具可能支持相关分析，但没有暴露出与本文相同的数据契约或估计目标。

工具	主要范围	植物背景	环境/LD 处理	本文使用的证据
PlantMR 1.1	植物摘要统计 MR 和环境效应异质性	原生记录物种、组装、组织、阶段、多倍体和 LD 来源	带符号 LD 和可选环境协方差；要求完整网格	模拟、LD 压力测试和 Arabidopsis 案例
MRBGR [17]	大规模多组学、GWAS 和 MR 工具箱	玉米和水稻案例；广泛的多组学工作流	MR/网络估计目标不同，不是本文的 G×E 协方差契约	文献范围比较
MR-Base / TwoSampleMR [10]	人类 GWAS 资源和双样本 MR 自动化	面向人类 GWAS 的公共资源生态	标准 MR 敏感性分析；植物元数据不是主要契约	文献范围比较
metaGE [25]	多环境 GWAS 荟萃分析	植物多环境试验和 G×E QTL 检测	在 GWAS 荟萃分析层面建模异质性和环境协变量	估计目标比较；未重新实现
MAPtools [36]	mapping-by-sequencing 和 QTL-Seq 命令行分析	在植物和多物种 mapping 工作流中测试	变异/QTL 定位，不是摘要统计 MR 协方差	工作流/软件论文比较

环境效应异质性模型

对于 SNP j 和环境 k ，比值估计为 $r_{jk} = \beta_{y,jk} / \beta_{x,jk}$ 。令 z_k 为预先指定的数值环境分数。PlantMR 拟合 $r_{jk} = \theta_0 + \theta_1 z_k + \varepsilon_{jk}$ 。 θ_0 表示 $z=0$ 时的遗传代理效应， θ_1 表示 MR 效应随环境分数每增加一个单位的变化量。这是一个效应异质性模型。它的截距不是 MR-GxE 中的多效性截距，也不被解释为水平多效性的校正项。

一阶 Delta 方差为 $v_{jk} = \text{se}_{y,jk}^2 / \beta_{x,jk}^2 + \beta_{y,jk}^2 \text{se}_{x,jk}^2 / \beta_{x,jk}^4$ 。在以 SNP 为主、环境为次的排列方式下，可选的带符号 SNP 相关矩阵和环境相关矩阵定义 $V = D(R_{\text{SNP}} \otimes R_{\text{ENV}})D$ ，其中 D 为比值标准误差构成的对角矩阵。GLS 估计量为 $\theta_{\text{hat}} = (X'V^{-1}X)^{-1}X'V^{-1}r$ ，其中 $X=[1,z]$ 。如果 V 秩亏，残余异质性自由度为 $\text{rank}(V) - \text{rank}(X)$ 。

该模型要求每个 SNP 都有完整的环境网格，并且只保留在每个环境中都满足暴露 P 值、F 统计量和 MAF 要求的 SNP。这样可以避免把工具变量组成的改变误认为环境斜率。缺少环境相关性并不被当作已确认的独立性；报告会明确说明使用了对角近似。

实现细节

本研究按软件/方法学评估组织。我们没有利用真实数据案例选择有利的估计器、定义新的基因层面结论或调节模拟真值。主要结论集中于输入检查、考虑协方差的估计和诊断透明度。

输入模式和等位基因协调

必需的摘要统计列为 SNP、effect_allele、other_allele、beta、se 和 pval。可选列为 eaf 和 n。数据模式会拒绝空的或重复的 SNP 标识符、非有限数值、非正标准误、无效 P 值、无效等位基因字符以及效应等位基因和另一等位基因相同的记录。协调程序能够识别对齐、反向、互补和反向互补等位基因，并利用等位基因频率只保留能够解析的回文变异。

工具变量选择

Arabidopsis 案例的主要阈值为暴露 $P \leq 5 \times 10^{-8}$ 、 $F \geq 10$ 和 $MAF \geq 0.05$ 。GxE 选择器要求保留的每个 SNP 在每个环境中都通过这些筛选。这样可以避免环境特异的工具变量组成被误认为效应异质性。LD 使用带符号的相关系数表示，而不是使用 r^2 值。

估计器和诊断

标准方法包括 Wald 比值、固定效应 IVW、随机效应 IVW、MR-Egger、Cochran Q 和留一法分析。环境斜率估计器使用上文所述的 Delta 法比值方差和 GLS 协方差。如果协方差矩阵奇异，则对二次型使用 Moore–Penrose 逆，并按矩阵秩调整 Q 的自由度。

模拟设计

所有模拟都使用固定随机种子，并记录在元数据 JSON 文件中。基础基准使用 20 个 SNP 和 4 个环境分数（-1.5、-0.5、0.5、1.5）。暴露效应被生成为正向且强的工具变量。结局效应由汇总效应、已知环境斜率和多元正态抽样误差生成。LD 压力测试额外使用了 $\rho=0.6$ 的 AR(1) LD 相关矩阵。

Arabidopsis 数据处理

从 GEO 下载 GSE80744 标准化表达矩阵，并提取 AT1G11560 行。使用 1001 Genomes HDF5 矩阵提取局部区域；每隔 1000 个标记计算 5 个主成分。公共材料的 VCF 提供 REF/ALT 标签。根据材料 ID 合并 AraPheno FT10 和 FT16 数值。局部关联回归纳入基因型和 PC1–PC5。案例中记录了源 URL、哈希值、生成表格和限制条件。

统计报告

所有数值结果均报告效应估计、标准误、P 值、工具变量数量、协方差来源和异质性诊断，遵循 STROBE-MR 的报告原则。[13] 单基因 Arabidopsis 演示不作全基因组多重检验结论。任何未来的全基因组分析都必须预先规定基因层面聚合方式、多重检验控制和独立验证集。

结果

模拟校准和 LD 压力测试

主要模拟基准使用 20 个工具变量、4 个环境、环境相关性 0.5、暴露标准误 0.01、结局标准误 0.04，以及每个场景 500 次重复。场景包括零斜率、真实斜率为 0.25 和共同方向性多效性。LD 压力测试使用相同维度，并采用 $\rho=0.6$ 的 AR(1)带符号 LD 相关矩阵，比较正确协方差设定与对角独立近似。

表 3。主要模拟校准和 LD 压力测试汇总。图 2 和图 3 中的虚线在适用时表示名义拒绝率 0.05 和覆盖率 0.95。

场景	协方差	均值/偏差	覆盖率	拒绝率或功效
Null	环境感知	斜率偏差-0.00069	0.946	0.054
Null	对角	斜率偏差-0.00071	0.994	0.006
Causal G×E	环境感知	均值 0.24982; 偏差 -0.00018	0.952	1.000
Causal G×E	对角	均值 0.24832; 偏差 -0.00168	1.000	1.000
LD 压力测试零假设	正确 LD+环境协方差	偏差 0.00172	0.956	0.044
LD 压力测试零假设	错配对角模型	偏差 0.00177	0.874	0.126
LD 压力测试因果场景	正确 LD+环境协方差	偏差 0.00136	0.970	1.000
LD 压力测试因果场景	错配对角模型	偏差 0.00170	0.880	1.000

方向性多效性场景暴露出一个重要限制。当真实斜率为零时，环境斜率仍近似无偏，但合并截距偏高 +0.216。因此，环境斜率稳定并不能证明合并的因果关系不受水平多效性影响。




图 2。模拟校准。(a) 各场景的平均斜率估计及模拟均值的 95% 置信区间，虚线段表示数据生成值；(b) 拒绝比例；(c) 95% 覆盖率；(d) 方向性多效性使截距发生偏移，而环境斜率仍接近其目标值。




图 3。LD 压力测试。(a) 零假设 P 值的经验校准；(b) 斜率抽样分布；(c) 覆盖率；(d) 相对标准误差失真，均基于给定的 LD 和环境依赖结构。独立性近似使零假设拒绝率从 0.044 升至 0.126，使覆盖率为 0.956 降至 0.874。

共享输入的外部方法比较

我们根据 Spiller 等人提出的三步构造，实现了一个范围有限的摘要统计 MR-GxE 比较器。[14] 该比较器只使用每个环境中的暴露关联来建立一个固定加权的等位基因分数，然后计算分数—暴露和分数—结局关联，并带截距回归后者。两种方法使用相同的 20 个 SNP、4 个环境层、环境相关矩阵、标准误和每个场景 500 次重复。该比较是按方法各自的估计目标进行的，而不是制作一个总性能排行榜：PlantMR 估计环境效应斜率，而摘要 MR-GxE 估计不变因果效应和恒定多效性截距。

表 4。共享输入的 PlantMR 与摘要统计 MR-GxE 基准比较。只有当模拟数据生成模型定义了相应估计目标时，才报告偏差和覆盖率；目标不一致的输出保留为诊断。

场景	方法/目标	平均估计	偏差	覆盖率	拒绝率	解释
零因果效应+多效性	摘要 MR-GxE/因果效应	-0.0021	-0.0021	0.934	0.066	目标明确的因果校准
零因果效应+多效性	PlantMR/环境斜率	-0.0692	—	—	—	仅作参考：多效性使斜率不再具有因果含义
恒定效应、无多效性	PlantMR/环境斜率	0.0036	0.0036	0.938	0.062	目标明确的异质性校准

恒定效应、无多效性	摘要 MR-GxE/因果效应	0.5003	0.0003	0.958	1.000	目标明确的因果校准
恒定效应+多效性	摘要 MR-GxE/因果效应	0.4983	-0.0017	0.938	1.000	在恒定多效性下恢复正确因果目标
恒定效应+多效性	PlantMR/环境斜率	-0.0653	—	—	—	仅作参考：不是因果斜率
环境效应异质性	PlantMR/环境斜率	0.2515	0.0015	0.942	1.000	正确的环境斜率目标
环境效应异质性	摘要 MR-GxE/因果效应	1.2143	—	—	—	仅作参考：不变效应目标在此场景未定义

这一比较支持的是互补性，而不是某个方法胜出。在恒定因果效应和方向性多效性场景下，摘要 MR-GxE 恢复了因果效应（均值 0.4983，覆盖率 0.938），而 PlantMR 环境斜率是由排除限制被违反所产生的诊断信号。在真实存在环境效应异质性且没有多效性的场景下，PlantMR 恢复了环境斜率（均值 0.2515，覆盖率 0.942），而摘要 MR-GxE 输出并不对应同一个因果估计目标。因此，外部比较说明的是方法范围和假设，而不是某个方法全面优于另一个方法。




图 5。共享输入比较。（a）显示目标明确的估计，并用菱形标出生成真值；（b）只对估计目标明确的方法—场景组合显示覆盖率，灰色单元格表示目标不同，因此不评分。

Arabidopsis 数据契约案例

Arabidopsis 案例的目的，是演示公开数据工作流和诊断，而不是进行新的因果发现。从 GSE80744 标准化表达矩阵中提取 AT1G11560 的基线叶片表达，从 1001 Genomes v3.1 矩阵中提取局部基因型，并从 AraPheno 中提取 10°C 和 16°C 开花时间。局部关联模型使用带 5 个全基因组主成分的普通最小二乘回归，遵循植物关联分析中需要建模群体结构和亲缘关系的一般原则，[29–34] 但没有把它写成已重新实现发表研究中的混合模型/SMR 分析。[19–24]

表 5。Arabidopsis 数据契约的输入和局部处理。

层面	公共来源	局部处理
分子暴露	GSE80744 标准化表达	AT1G11560 行；log1p 变换；基线暴露

基因型	1001 Genomes v3.1	Chr1:3,861,124–3,901,085; 3,352 个局部 SNP; 5 个主成分
结局环境 1	AraPheno FT10	10°C 开花时间; $z=-3$
结局环境 2	AraPheno FT16	16°C 开花时间; $z=+3$
等位基因	1001 Genomes 材料 VCF	为剂量编码矩阵建立 REF/ALT 对应关系

在 $P \leq 5 \times 10^{-8}$ 、 $F \geq 10$ 和 $MAF \geq 0.05$ 的条件下，48 个 SNP 在两个环境中都通过筛选。由于它们之间存在较强相关，主要分析提供了带符号的 LD 相关矩阵。主要的对角环境协方差分析估计截距为 2.3601 (SE 0.4685, $P=4.72 \times 10^{-7}$)，环境斜率为 -0.03705 (SE 0.15617, $P=0.81249$)。残余异质性为 $Q=192.89$ ，自由度为 60 (按矩阵秩调整)， $P=7.33 \times 10^{-16}$ 。

表 6。Arabidopsis 案例的工具变量审计。各排除数量可能来自重叠诊断，不能相加后当作互不重叠的阶段数量。

审计阶段	数量	解释
原始完整 SNP×环境网格	172 个 SNP/344 行	每个原始局部 SNP 都有两个环境的记录。
有歧义的回文变异排除	每个环境 3 个	在等位基因协调阶段排除；剩余 169 个 SNP/338 行。
P 值诊断排除	121 行	与其他质量控制排除重叠，不是独立阶段数量。
F 统计量诊断排除	106 行	与 P 值和完整网格诊断重叠。
最终完整网格工具变量	48 个 SNP/96 行	在两个环境中均满足预先设定的 P 值、F 和 MAF 要求。
LD 矩阵/协方差秩	48×48 LD; rank(V)=62	考虑矩阵秩的 Q 使用 $62-2=60$ 个残余自由度。

表 7。按环境分层的比较估计。估计来自局部 OLS 摘要统计演示，不是因果模型的独立验证。

环境	估计器	估计值	SE	P 值	Q (P 值)
10°C	固定效应 IVW	6.6001	0.2038	4.999×10^{-230}	84.90 (5.89×10^{-4})
10°C	随机效应 IVW	7.0842	0.2970	1.030×10^{-125}	84.90 (5.89×10^{-4})
10°C	MR-Egger	4.2259	0.5188	3.758×10^{-16}	—
16°C	固定效应 IVW	8.2379	0.2933	1.402×10^{-173}	97.70 (2.05×10^{-5})
16°C	随机效应 IVW	8.8667	0.4561	3.598×10^{-84}	97.70 (2.05×10^{-5})
16°C	MR-Egger	6.7552	0.7683	1.466×10^{-18}	—

两个环境的 IVW 估计均为正，但大小不同（固定效应 IVW 在 10°C 为 6.6001，在 16°C 为 8.2379）。它们的异质性统计量显著，这为环境斜率分析提供了动机，但本身不能识别环境效应。MR-Egger 估计值更低，并且截距诊断较大（10°C 截距为 2.9281, $P=3.59 \times 10^{-8}$ ；16°C 截距为 2.0160, $P=0.0103$ ），说明多效应性应被视为尚未解决的限制，而不是已经解决的问题。

敏感性分析使用 1,122 个共享 AraPheno 材料中 FT10 和 FT16 的 Pearson 相关性 ($r=0.88195$) 作为表型相关性代理。该分析估计截距为 1.8027 (SE 0.6217, $P=0.00374$)，斜率为 -0.08228 (SE 0.06634, $P=0.21491$)。该代理值不是已知的比值误差协方差，因此不作为主要推断。

解释 本案例说明 PlantMR 可以把植物数据来源、LD 依赖、完整网格选择和协方差近似明确呈现出来。它不能证明 AT1G11560 具有因果作用，因为表达队列和结局队列存在材料重叠，没有估计暴露—结局协方差，局部 OLS 不同于发表的混合模型，并且残余异质性仍然存在。




图 4。Arabidopsis 植物 MR 案例。(a) AT1G11560 案例中对齐的暴露和结局区域关联轨道；(b) 48 个保留工具变量之间的 LD；(c) 按环境分层的 MR 估计；(d) 主要分析和表型相关性代理下的环境斜率。误差条表示 95% 置信区间。

可复现性和运行时间

本地运行基准以返回码 0 完成了验证、合成 G×E 运行和 Arabidopsis 案例。三个任务耗时 9.70–9.93 秒，峰值常驻内存为 126,664–133,424 KB。这些结果是单台主机上的可复现性基准，不代表普遍性能，也不代表全基因组规模的可扩展性。

表 8。冻结版 PlantMR 实现的本地运行基准。

任务	用时 (秒)	峰值 RSS (KB)	返回码
validate	9.7034	126,664	0
gxe_synthetic	9.7974	129,736	0
gxe_arabidopsis	9.9300	133,424	0

讨论

主要发现

PlantMR 针对植物摘要统计 MR 中的一个反复出现的问题：基因型、组织、发育阶段、环境、LD 和样本重叠信息经常被分别保存。该工作流将这些字段与估计结果联系起来，并带入报告。这一点很重要，因为当暴露组织、发育阶段或处理条件发生变化时，同一个 SNP 层面的 beta 和标准误可能对应不同的估计目标。因此，本文的贡献是一个可复现的数据和分析工作流，而不是关于植物因果关系的新声明。

环境斜率分析回答的是一个更具体的问题：遗传代理的暴露—结局关联是否沿着预先指定的环境尺度发生变化？该斜率不是普遍适用的基因—环境因果参数，也不是多效性校正截距。它的使用依赖于共同的 SNP×环境工具变量网格、具有生物学解释的环境对比以及与数据结构相匹配的协方差模型。

模拟结果说明这些细节为什么会影响推断。在本研究测试场景下，正确协方差模型和对角模型给出了相近的点估计，但在 LD 压力测试中，独立性近似降低了标准误。零假设拒绝率从 0.044 升至 0.126，覆盖率从 0.956 降至 0.874。因此，在依赖性合理存在时，应报告协方差来源，并把对角分析作为敏感性分析，而不是默认的真实模型。

与相关方法的比较

PlantMR 应当与已有 MR 方法配合使用。IVW、MR-Egger、稳健估计器和中位数估计器、多效性诊断、共定位及精细定位分别处理不同的不确定性来源。[3–12,28] 本文纳入的标准估计器提供共同的审计记录，但不能让无效工具变量变得有效。因此，Arabidopsis 案例中的较大 Q 统计量和非零 Egger 截距是结果的一部分，不是通过更换另一个估计器就可以消除的问题。

共享输入比较也区分了 PlantMR 和交互 MR。摘要统计 MR-G×E 利用工具变量—暴露关联中的基因—协变量交互，并在相应假设下估计不变因果效应和多效性项。[14] MR-GENIUS 采用不同的识别策略，对交互强度和异质性有自己的条件要求。[15] MR-EILLS 针对异质 GWAS 摘要数据中的不变因果效应。[16] PlantMR 则估计效应沿观测环境尺度的变化。这四种量不能互相替换。

PlantMR 与植物生物学 MR 应用的区别，在于证据目标不同。Liu 等人将玉米干旱响应表达、eQTL、MR 优先排序和实验跟进结合起来，提出了干旱耐受调控因子的候选名单。[18] Feng 等人利用 Arabidopsis 区域 GWAS 和 eQTL 摘要统计、SMR/HEIDI 以及独立表达数据，对 AT1G11560 进行候选优先排序。[19] 在 Populus 研究中，Liang 等人通过关联分析、上位性、表达和 MR 分析，把一个 miRNA 及其靶基因的变异与木材性状联系起来。[37] 这些研究为本文的图形顺序提供了更直接的植物 MR 参照：环境或组织背景、区域遗传证据、分子关联、MR 估计以及生物学解释边界。MRBIGR 在玉米中整合基因型、转录组、代谢组、GWAS 和 MR 分析，并用玉米和水稻数据展示工作流。[17] metaGE 面向多环境 GWAS 荟萃分析，并在多个植物数据集上比较固定效应、随机效应和其他荟萃分析程序。[25] MAPtools 强调命令行工作流、公开数据案例和可复现输出。[36] PlantMR 采用植物研究中常见的证据顺序，但把重点放在考虑协方差的摘要统计 MR 上，而不是声称发现了新的生物学结论。

模拟和协方差行为

植物群体经常包含相关材料、局部单倍型和不均匀 LD。因此，不能因为输入文件每行对应一个 SNP，就假设比值估计的协方差矩阵是对角的。当相同材料被重复表型测量、试验共享对照或环境测量彼此相关时，环境之间也会产生依赖。在这些情况下，协方差模型对标准误和异质性的影响通常大于对点估计的影响。

考虑矩阵秩的 Q 计算，为奇异或近似奇异的协方差矩阵提供了直接处理方式。主要案例有 96 个比值观测，但给定协方差矩阵的秩为 62。因此，报告的残余自由度为 $\text{rank}(V) - \text{rank}(X) = 60$ ，而不是 94 或 95。这个计算不能验证协方差矩阵在生物学上是否正确，但可以避免把线性依赖的观测当作相互独立。

压力测试还区分了校准和功效。在真实斜率为 0.25 的测试中，两种协方差选择的功效均为 1.00，但对角模型未能保持零假设校准。只用功效评价会漏掉这一差异。因此，对于考虑协方差的方法，应同时报告零假设拒绝率、覆盖率、偏差、RMSE 和标准误表现。

Arabidopsis 数据应用

Arabidopsis 分析被用作一个公开数据工作流案例。局部区域提供了完整的双环境网格；有歧义的回文变异被排除，48 个 SNP 通过最终工具变量筛选。按环境分层的固定效应 IVW 估计在两个温度下均为正，但大小不同。考虑协方差的环境斜率为 -0.03705 (SE 0.15617 , $P=0.81249$)，而残余异质性较高 ($Q=192.89$ ，按矩阵秩调整的自由度为 60, $P=7.33 \times 10^{-16}$)。

该案例不能证明 AT1G11560 是开花时间的因果调控因子。表达队列和结局队列存在材料重叠，暴露—结局抽样协方差不可得，局部关联模型使用普通最小二乘而不是发表的混合模型。基线表达代理还被直接带入两个结局环境，而不是作为环境特异的 eQTL 重新估计。适当的解释是：PlantMR 能够暴露这些依赖关系，并产生可复现的敏感性结果；生物学结论仍然是暂时性的。

表型相关性敏感性分析说明了同一问题。FT10 与 FT16 的相关性改变了拟合截距和斜率，但它不是暴露和结局 GWAS 估计值的实测协方差。因此，它可以作为敏感性计算，而不是样本重叠的正式校正。报告这个代理值及其性质，可以避免把一个方便获得的相关性误认为已识别的协方差。

在植物和作物研究中的使用

对于自然群体研究，报告应说明材料面板、地理结构处理策略、亲缘关系或混合模型方法、参考基因组组装，以及构建 LD 矩阵时使用的等位基因表示方式。对于育种群体和多环境试验，环境分数应在分析前定义，并代表具有生物学意义的对比，而不是事后命名的标签。温度、干旱程度、光周期或营养水平等变量的测量误差及其试验间相关性也应记录。

表达介导分析还要求把暴露背景与关联结果绑定。每个 eQTL 都应报告组织、发育阶段、处理条件和标准化方式。不能把基线 eQTL 不加说明地当作胁迫特异分子暴露。若生物学问题是中介作用，除了 MR 之外，还需要共定位、精细定位或 HEIDI 类证据。[11,12,28] 如果问题是环境特异的生物学效应，可能还需要对暴露关联本身进行环境特异建模。

多倍体剂量、同源异源基因归属、亚基因组特异 LD、存在/缺失变异和结构变异都需要明确的数据模型。在当前实现中，这些变异不会被静默地重新编码为二倍体 SNP。这样可以把软件限制与生物学阴性结果区分开，并明确未来解释这些分析所需的输入条件。

局限性

Arabidopsis 案例不是独立的因果验证。它使用公开处理数据、重叠材料和局部 OLS 模型。案例只有两个结局环境，因此斜率只是预先指定环境尺度上的对比，不能证明线性关系、阈值效应或一般响应曲线。

方向性多效性模拟只覆盖一个结构化场景，没有覆盖平衡多效性、相关多效性、弱工具变量、非线性效应、环境测量误差、赢家诅咒或群体分层 LD 错配。当前软件接收外部提供的带符号相关矩阵，但不会估计因果 LD 面板、修复所有非半正定输入，或建模多倍体剂量和结构变异。

外部比较明确限于一个摘要统计 MR-GxE 实现。完整的个体水平 MR-GxE 分析以及 MR-GENIUS 或 MR-EILLS 的独立实现不在当前研究范围内。只有在对齐输入契约和目标估计量之后，才适合比较这些方法。若要把生物学结论推广到本演示之外，还需要在独立群体、更多环境、混合模型摘要统计和功能证据中扩展评估。

结论

PlantMR 提供了一个用于植物摘要统计 MR 和环境效应异质性分析的可复现 workflow。本文证据包括明确的元数据、完整网格工具变量选择、考虑协方差的 GLS、考虑矩阵秩的异质性报告、校准模拟、共享输入 MR-GxE 比较和公开 Arabidopsis 案例。这些结果支持使用 PlantMR 把假设和数据依赖关系明确呈现出来；但它们不能证明 AT1G11560 是因果基因，也不能让 PlantMR 替代共定位、混合模型 GWAS、交互 MR 方法或功能验证。

可用性和运行要求

PlantMR 以 MIT 许可证发布。软件版本为 v1.1.0，完整的手稿、基准结果和 Word 文档包冻结在 v1.1.0-paper 标签。公共代码仓库为 <https://github.com/Zhangzhishuai-HIT/PlantMR>，供投稿使用的源码归档为 release/PlantMR_v1.1.0-paper_source.zip。Zenodo 或等效归档 DOI 尚待分配。

公共数据来源包括 GSE80744 标准化表达数据、AraPheno FT10/FT16、1001 Genomes v3.1 以及 Arabidopsis 相关原始研究。1001 Genomes 的大型提供方归档不随项目重新分发；项目包含派生的局部基因型区域、主成分分数、等位基因对应关系和提供方校验值。玉米补充工作簿、eQTL 表和候选基因表被纳入审计材料，但没有被当作新的因果结果。

表 9。Plant Methods 软件可用性和运行要求。

字段	当前值
项目名称	PlantMR 1.1
项目主页	https://github.com/Zhangzhishuai-HIT/PlantMR
操作系统	已在 Linux 上验证；目标是可移植的 Python 代码。
编程语言	Python 3.10 或更高版本。
依赖	NumPy、pandas、SciPy、statsmodels、matplotlib 和 psutil；已在 environment.yml 中声明。
许可证	MIT 许可证。
非学术使用限制	当前许可证没有额外限制。

缩略语

缩略语	定义
MR	Mendelian randomization, 孟德尔随机化
GWAS	Genome-wide association study, 全基因组关联研究
eQTL	Expression quantitative trait locus, 表达数量性状位点
G×E / GxE	Genotype-by-environment interaction, 基因型—环境互作, 或环境效应异质性
LD	Linkage disequilibrium, 连锁不平衡
GLS	Generalized least squares, 广义最小二乘
IVW	Inverse-variance weighted, 逆方差加权
MAF	Minor allele frequency, 次要等位基因频率
SNP	Single-nucleotide polymorphism, 单核苷酸多态性
Q	Cochran-type heterogeneity statistic, Cochran 类异质性统计量

声明

声明项目	状态
伦理审批和参与同意	不适用：使用的是公共植物材料和公共汇总/处理数据。
发表同意	不适用。
数据和材料可得性	上文说明了公共源数据和派生审计材料；代码位于 https://github.com/Zhangzhishuai-HIT/PlantMR

	github.com/Zhangzhishuai-HIT/PlantMR; 归档 DOI 待分配。
利益冲突	待作者补充。
基金	待作者补充。
作者贡献	待作者补充。
致谢	待作者补充，或标记为不适用。
作者信息	作者姓名、单位和通讯作者信息待补。

参考文献

1. Davey Smith, G. & Ebrahim, S. "Mendelian randomization": can genetic epidemiology contribute to understanding environmental determinants of disease? *Int. J. Epidemiol.* 32, 1–22 (2003). <https://doi.org/10.1093/ije/dyg070>
2. Lawlor, D. A., Harbord, R. M., Sterne, J. A. C., Timpson, N. & Smith, G. D. Mendelian randomization: using genes as instruments for making causal inferences in epidemiology. *Stat. Med.* 27, 1133–1163 (2008). <https://doi.org/10.1002/sim.3034>
3. Burgess, S., Butterworth, A. & Thompson, S. G. Mendelian randomization analysis with multiple genetic variants using summarized data. *Genet. Epidemiol.* 37, 658–665 (2013). <https://doi.org/10.1002/gepi.21758>
4. Bowden, J., Davey Smith, G. & Burgess, S. Mendelian randomization with invalid instruments: effect estimation and bias detection through Egger regression. *Int. J. Epidemiol.* 44, 512–525 (2015). <https://doi.org/10.1093/ije/dyv080>
5. Bowden, J., Davey Smith, G., Haycock, P. C. & Burgess, S. Consistent estimation in Mendelian randomization with some invalid instruments using a weighted median estimator. *Genet. Epidemiol.* 40, 304–314 (2016). <https://doi.org/10.1002/gepi.21965>
6. Hartwig, F. P., Davey Smith, G. & Bowden, J. Robust inference in summary data Mendelian randomization via the zero modal pleiotropy assumption. *Int. J. Epidemiol.* 46, 1985–1998 (2017). <https://doi.org/10.1093/ije/dyx102>
7. Verbanck, M. et al. Detection of widespread horizontal pleiotropy in causal relationships inferred from Mendelian randomization between complex traits and diseases. *Nat. Genet.* 50, 693–698 (2018). <https://doi.org/10.1038/s41588-018-0099-7>
8. Zhao, Q., Wang, J., Hemani, G., Bowden, J. & Small, D. S. Statistical inference in two-sample summary-data Mendelian randomization using robust adjusted profile score. *Ann. Statist.* 48, 1742–1769 (2020). <https://doi.org/10.1214/19-AOS1866>
9. Burgess, S. et al. Guidelines for performing Mendelian randomization investigations: update for summer 2023. *Wellcome Open Res.* 4, 186 (2023). <https://doi.org/10.12688/wellcomeopenres.15555.3>
10. Hemani, G. et al. The MR-Base platform supports systematic causal inference across the human phenome. *eLife* 7, e34408 (2018). <https://doi.org/10.7554/eLife.34408>
11. Zhu, Z. et al. Integration of summary data from GWAS and eQTL studies predicts complex trait gene targets. *Nat. Genet.* 48, 481–487 (2016). <https://doi.org/10.1038/ng.3538>
12. Zhu, Z. et al. Causal associations between risk factors and common diseases inferred from GWAS summary data. *Nat. Commun.* 9, 224 (2018). <https://doi.org/10.1038/s41467-017-02317-2>
13. Skrivankova, V. W. et al. Strengthening the reporting of observational studies in epidemiology using Mendelian randomization: the STROBE-MR statement. *JAMA* 326, 1614–1621 (2021). <https://doi.org/10.1001/jama.2021.18236>
14. Spiller, W. et al. Detecting and correcting for bias in Mendelian randomization analyses using Gene-by-Environment interactions. *Int. J. Epidemiol.* 48, 702–712 (2019). <https://doi.org/10.1093/ije/dyy204>

15. Spiller, W., Hartwig, F. P., Sanderson, E., Davey Smith, G. & Bowden, J. Interaction-based Mendelian randomization with measured and unmeasured gene-by-covariate interactions. *PLoS ONE* 17, e0271933 (2022). <https://doi.org/10.1371/journal.pone.0271933>
16. Hou, L., Chen, H. & Zhou, X.-H. MR-EILLS: an invariance-based Mendelian randomization method integrating multiple heterogeneous GWAS summary datasets. *Nat. Commun.* 16, 1–15 (2025). <https://doi.org/10.1038/s41467-025-62823-6>
17. Xu, F. et al. MRBGR: a versatile toolbox for genetic regulation inference from population-scale multi-omics data. *Plant Commun.* 6, 101197 (2025). <https://doi.org/10.1016/j.xplc.2024.101197>
18. Liu, S. et al. Mapping regulatory variants controlling gene expression in drought response and tolerance in maize. *Genome Biol.* 21, 163 (2020). <https://doi.org/10.1186/s13059-020-02069-1>
19. Feng, X. et al. Dual-trait genomic analysis in highly stratified *Arabidopsis thaliana* populations using genome-wide association summary statistics. *Heredity* 133, 11–20 (2024). <https://doi.org/10.1038/s41437-024-00688-z>
20. The 1001 Genomes Consortium. 1,135 Genomes reveal the global pattern of polymorphism in *Arabidopsis thaliana*. *Cell* 166, 481–491 (2016). <https://doi.org/10.1016/j.cell.2016.05.063>
21. Kawakatsu, T. et al. Epigenomic diversity in a global collection of *Arabidopsis thaliana* accessions. *Cell* 166, 492–505 (2016). <https://doi.org/10.1016/j.cell.2016.06.044>
22. Schmitz, R. J. et al. Patterns of population epigenomic diversity. *Nature* 495, 193–198 (2013). <https://doi.org/10.1038/nature11968>
23. Atwell, S. et al. Genome-wide association study of 107 phenotypes in *Arabidopsis thaliana* inbred lines. *Nature* 465, 627–631 (2010). <https://doi.org/10.1038/nature08800>
24. Brachi, B. et al. Linkage and association mapping of *Arabidopsis thaliana* flowering time in nature. *PLoS Genet.* 6, e1000940 (2010). <https://doi.org/10.1371/journal.pgen.1000940>
25. De Walsche, A. et al. metaGE: investigating genotype × environment interactions through GWAS meta-analysis. *PLoS Genet.* 21, e1011553 (2025). <https://doi.org/10.1371/journal.pgen.1011553>
26. Sul, J. H. et al. Accounting for population structure in gene-by-environment interactions in genome-wide association studies using mixed models. *PLoS Genet.* 12, e1005849 (2016). <https://doi.org/10.1371/journal.pgen.1005849>
27. An, X. et al. An approach to identify gene-environment interactions and reveal new biological insight in complex traits. *Nat. Commun.* 15, 1–16 (2024). <https://doi.org/10.1038/s41467-024-47806-3>
28. Giambartolomei, C. et al. Bayesian test for colocalisation between pairs of genetic association studies using summary statistics. *PLoS Genet.* 10, e1004383 (2014). <https://doi.org/10.1371/journal.pgen.1004383>
29. Price, A. L. et al. Principal components analysis corrects for stratification in genome-wide association studies. *Nat. Genet.* 38, 904–909 (2006). <https://doi.org/10.1038/ng1847>
30. Kang, H. M. et al. Efficient control of population structure in model organism association mapping. *Genetics* 178, 1709–1723 (2008). <https://doi.org/10.1534/genetics.107.080101>
31. Zhou, X. & Stephens, M. Genome-wide efficient mixed-model analysis for association studies. *Nat. Genet.* 44, 821–824 (2012). <https://doi.org/10.1038/ng.2310>
32. Lipka, A. E. et al. GAPIT: genome association and prediction integrated tool. *Bioinformatics* 28, 2397–2399 (2012). <https://doi.org/10.1093/bioinformatics/bts444>
33. Purcell, S. et al. PLINK: a tool set for whole-genome association and population-based linkage analyses. *Am. J. Hum. Genet.* 81, 559–575 (2007). <https://doi.org/10.1086/519795>

34. Chang, C. C. et al. Second-generation PLINK: rising to the challenge of larger and richer datasets. *GigaScience* 4, 7 (2015). <https://doi.org/10.1186/s13742-015-0047-8>
35. Kang, M. et al. The pan-genome and local adaptation of *Arabidopsis thaliana*. *Nat. Commun.* 14, 6259 (2023). <https://doi.org/10.1038/s41467-023-42029-4>
36. Candela, H. et al. MAPtools: command-line tools for mapping-by-sequencing and QTL-Seq analysis and visualization. *Plant Methods* 20, 107 (2024). <https://doi.org/10.1186/s13007-024-01222-2>
37. Liang, X. et al. Association study and Mendelian randomization analysis reveal effects of the genetic interaction between PtoMIR403b and PtoGT31B-1 on wood formation in *Populus tomentosa*. *Front. Plant Sci.* 12, 704941 (2021). <https://doi.org/10.3389/fpls.2021.704941>